

# Estudo de Caso 01: Desempenho de uma nova versão de Software

*André Boechat, Mateus Pongelupe, Samuel Leite*

*24 de Setembro de 2018*

## Resumo

Este trabalho consiste no primeiro estudo de caso da disciplina de Planejamento e Análise de Experimentos. Nele, foram executados testes para avaliar se o desempenho de uma nova versão de software é superior ao da anterior. A média e a variância do custo de execução foram as variáveis escolhidas para fazer essa medida, sendo que a versão atual do software possui um custo de execução dado por uma distribuição conhecida. **Os resultados alcançados <!-- !TODO - Adicionar resultados ao resumo --> ...**

## Planejamento do Experimento

Nesse experimento, está sendo avaliado o desempenho de uma nova versão de software. É conhecido que a versão atual do software possui uma distribuição para seu custo de execução com média populacional  $\mu = 50$  e variância populacional  $\sigma^2 = 100$ . Para a nova versão do software deseja-se investigar seus resultados quanto a melhorias de desempenho, isto é, menor custo médio de execução e/ou menor variância. Com esse intuito, foram desenvolvidos dois experimentos: um para avaliar a média e outro para avaliar a variância.

## Teste da média

Para avaliar se o desempenho do novo software é melhor que a versão antiga, está sendo observado se a média do custo de execução é menor. Assim, ao definir a hipótese  $H_1$ , podemos fazer com que ela seja unidirecional, isto é, a região de interesse do teste está na direção em que a média de execução da nova versão seja menor que a média atual. Dessa forma, a hipótese nula  $H_0$  e a hipótese  $H_1$  podem ser definidas como:

$$\begin{cases} H_0 : \mu \geq 50 \\ H_1 : \mu < 50 \end{cases}$$

Para esse teste, definiu-se um nível de significância de  $\alpha = 0.01$ , um efeito de relevância mínimo  $\delta^* = 4$  e uma potência desejada de  $\pi = 1 - \beta = 0.8$ .

```
h0.mean = 50
h0.sd = sqrt(100)

t1.alpha = 0.01
t1.delta = 4
t1.beta = 0.2
t1.power = 1 - t1.beta
```

Assumindo que a hipótese nula  $H_0$  se comporte com uma distribuição de média populacional  $\mu = 50$  e variância populacional  $\sigma^2 = 100$ , pode-se calcular o número de amostras mínimo a partir do teste Z, haja vista que a variância da hipótese nula é conhecida. Para fazer esse cálculo, foi usado o pacote *asbio*:

```
library(asbio)
n <- power.z.test(power = t1.power, alpha = t1.alpha, effect = t1.delta, sigma = h0.sd, test = "one.tai
t1.N <- ceiling(n)
cat("N: ", t1.N)
```

## N: 63

Assim, fazendo uso do teste Z, precisaremos de uma amostra de tamanho  $N = 63$  para executar o nosso teste com uma potência  $\pi = 0.8$ . Por nossa hipótese  $H_1$  ser unidirecional, a região crítica do teste Z pode ser determinada como:

$$P(z_\alpha \leq Z_0 | H_0 \text{ é verdadeira})$$

Isto é, para que a hipótese nula seja rejeitada com um nível de confiança de 99% é preciso que  $z_\alpha > Z_0$ .

## Teste da variância

A section detailing the experimental setup. This is the place where you will define your test hypotheses, e.g.:

$$\begin{cases} H_0 : \mu = 10 \\ H_1 : \mu < 10 \end{cases}$$

including the reasons behind your choices of the value for  $H_0$  and the directionality (or not) of  $H_1$ .

This is also the place where you should discuss (whenever necessary) your definitions of minimally relevant effects ( $\delta^*$ ), sample size calculations, choice of power and significance levels, and any other relevant information about specificities in your data collection procedures.

## Coleta de Dados

A coleta de dados foi simulada a partir da rotina sugerida no caso de uso, com uma pequena modificação: uma *seed* foi definida para a execução do programa, de forma a garantir sua reproducibilidade.

```
# Loading required package
library(ExpDE)
mre <- list(name = "recombination_bin", cr = 0.9)
mmu <- list(name = "mutation_rand", f = 2)
mpo <- 100
mse <- list(name = "selection_standard")
mst <- list(names = "stop_maxeval", maxevals = 10000)
mpr <- list(name = "sphere", xmin = -seq(1, 20), xmax = 20 + 5 * seq(5, 24))

# Setting seed so the program can be reproduced.
set.seed(1998)

# One sample
ExpDE(mpo, mmu, mre, mse, mst, mpr,
      showpars = list(show.iters = "none"))$Fbest
```

Em nossos experimentos, precisaremos coletar um número arbitrário  $N$  de amostras. Portanto, a partir das rotinas acima, foram criadas duas funções para essa coleta:

- *generate\_sample* : Coleta uma única amostra.
- *generate\_n\_samples* : Coleta  $n$  amostras no formato de um *data.frame*.

Segue abaixo a codificação dessas funções, bem como um exemplo da chamada de *generate\_n\_samples* para  $N = 10$ :

```
#Generates one sample
generate_sample <- function() {
  return(ExpDE(mpo, mmu, mre, mse, mst, mpr,
               showpars = list(show.iters = "none"))$Fbest);
}
```

```

}

#Generates n samples on the data.frame format
generate_n_samples <- function(n) {
  cost <- replicate(n, generate_sample())
  return(data.frame(cost))
}

#Example for N=10
generate_n_samples(10)

```

## Análise Estatística

### Teste da Média

Dados os parâmetros definidos na seção *Planejamento do Experimento* para o teste da média, foram recolhidas  $N = 63$  amostras e o teste foi executado nas linhas abaixo. O intervalo de confiança também foi calculado, considerando uma distribuição normal cuja variância populacional  $\sigma^2 = 100$  é conhecida.

```

## Getting the samples
t1.samples <- generate_n_samples(t1.N)
## Writing samples to csv file
write.csv(t1.samples, 'test-one.csv')

## Test Z Execution
t1.mean <- mean(t1.samples$cost)
t1.sd <- sd(t1.samples$cost)
z0 <- (t1.mean - h0.mean)/(h0.sd/sqrt(t1.N))
t1.z_alpha <- qnorm(t1.alpha)

## Confidence interval
t1.error <- qnorm(1-(t1.alpha/2)) * h0.sd / sqrt(n)

cat("\n",
"Mean: ", t1.mean, "\n",
"Z0: ", z0, "\n",
"Zalpha: ", t1.z_alpha, "\n",
"Confidence Interval: ", t1.mean - t1.error, " <= ", t1.mean, " <= ", t1.mean + t1.error, "\n")

##
## Mean: 50.78709
## Z0: 0.6247342
## Zalpha: -2.326348
## Confidence Interval: 47.53475 <= 50.78709 <= 54.03943

```

Como  $Z_\alpha < Z_0$ , conclui-se que não há evidências suficientes para rejeitar  $H_0$  a um nível de confiança de 99%.  
 Falta validar e discutir as assumptions e discutir a potência do teste -> um nível de confiança muito elevado pode levar a uma dificuldade de detectar que a hipótese nula é falsa. <!-- !TODO - Fazer análise da média -->  
 ...

### **Checking Model Assumptions**

The assumptions of your test should also be validated, and possible effects of violations should also be explored.

### **Conclusions and Recommendations**

The discussion of your results, and the scientific/technical meaning of the effects detected, should be placed here. Always be sure to tie your results back to the original question of interest!